TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Biometrická autentifikácia tváre s ochranou proti falšovaniu

Semestrálne zadanie z predmetu Biometrické systémy bezpečnosti

Vypracovali: Oleh Poiasnik, Andrii Pervashov
Vyučujúci: doc. Ing. Matúš Pleva, PhD., Ing. Eva Kupcová, PhD.
Akademický rok: 2026/2027

Košice 2026

Abstrakt

Práca sa zaoberá prihlasovaním pomocou tváre a ochranou takého prihlasovania pred podvrhmi, ako sú fotografie alebo videá prehrávané na displeji. Navrhli a implementovali sme webový systém, ktorý tvár sníma bežnou webkamerou a o výsledku rozhoduje na serveri. Ochrana je viacvrstvová: kontrola kvality snímky, rozpoznanie podvrhu z obrazu dvojicou neurónových sietí MiniFASNet, náhodná výzva na pohyb hlavy a kontrola, že sa osoba počas snímania nezmenila. Tvár sa porovnáva modelom SFace. Na databáze LFW sa pri prahu použitom v systéme nepomýlil ani raz v prospech cudzej osoby a odmietol 3,9 % dvojíc fotografií tej istej osoby. Detektor podvrhu prijal na databáze CASIA-FASD najviac 1,7 % útokov jedného druhu. Všetkých 30 pokusov o prihlásenie statickým obrázkom tváre bolo zamietnutých. Spracovanie jedného prihlásenia trvá na bežnom procesore približne 0,3 s.

Kľúčové slová: biometria, rozpoznávanie tváre, odhaľovanie podvrhov, živosť tváre, ISO/IEC 30107-3

Obsah

Abstrakt **1**

1 Úvod **6**

2 Analýza problematiky **7**
2.1 Ako funguje rozpoznávanie tváre 7
2.2 Kvalita biometrickej vzorky 8
2.3 Podvrhy pred kamerou 8
2.4 Odhaľovanie podvrhov 8
2.5 Ako sa meria úspešnosť 9

3 Návrh riešenia **10**
3.1 Architektúra 10
3.2 Spracovanie snímok 11
3.3 Výzva na pohyb hlavy 12
3.4 Bezpečnostný návrh 13
3.5 Ochrana biometrických údajov 13

4 Implementácia **15**
4.1 Použité technológie 15
4.2 Detekcia tváre a kontrola kvality 15
4.3 Rozpoznanie podvrhu z obrazu 16
4.4 Výzva a snímanie 16
4.5 Registrácia, overenie a identifikácia 17
4.6 Bezpečnosť a ochrana údajov 17
4.7 Klientska aplikácia 18
4.8 Nasadenie 20

5 Testovanie a vyhodnotenie **22**
5.1 Ako počítame chyby 22
5.2 Automatické testy 23
5.3 Presnosť rozpoznávania tváre 23

5.4 Rozpoznávanie podvrhov z obrazu 24
5.5 Testy celého systému 26
5.6 Rýchlosť 28
5.7 Obmedzenia experimentálneho vyhodnotenia 28

6 Príručka a dokumentácia **30**
6.1 Archivácia a opakovateľnosť 30
6.2 Inštalácia a spustenie 30
6.3 Príručka používateľa 32
6.4 Rozhranie servera 33

7 Záver **35**

Zoznam použitej literatúry **36**

A Obsah repozitára **39**

Zoznam obrázkov

3.1 Architektúra systému 10
3.2 Spracovanie jednej snímky 11

4.1 Úvodná stránka a registrácia 18
4.2 Prihlásenie – tvár je v kruhu a spĺňa požiadavky na kvalitu 19
4.3 Výzva na pohyb hlavy počas prihlásenia 19
4.4 Používateľský účet a správa systému 20

5.1 Rozpoznávanie tváre na databáze LFW 24
5.2 Rozpoznávanie podvrhov na databáze CASIA-FASD 26

Zoznam tabuliek

3.1 Vrstvy serverovej časti 11
3.2 Hrozby a protiopatrenia 13

4.1 Použité technológie 15

5.1 Čo overujú automatické testy 23
5.2 Rozpoznávanie tváre na databáze LFW (6000 dvojíc) 24
5.3 Snímky použité na vyhodnotenie (CASIA-FASD, testovacia časť) . . . 25
5.4 Chyby rozpoznávania podvrhov pri rôznych hraniciach (jednotlivé snímky) 25
5.5 Rozpoznávanie podvrhov na databáze CASIA-FASD (hranica 0,50) . . 26
5.6 Útok statickým obrázkom 27
5.7 Scenáre testu so živými používateľmi 27
5.8 Čas spracovania jednej snímky (640 × 360 bodov) v milisekundách . . . 28

6.1 Najdôležitejšie nastavenia 32
6.2 Časté hlásenia a ich riešenie 33
6.3 Hlavné adresy rozhrania servera (predpona `/api/v1`) 33

Kapitola 1

Úvod

Odomknúť telefón pohľadom do kamery je dnes úplne bežné a podobne sa tvárou prihlasujeme aj do bankových aplikácií či pri overovaní totožnosti na diaľku. Je to pohodlné – netreba si pamätať heslo a tvár so sebou nosíme stále. Má to však háčik: tvár nie je tajomstvo. Fotku človeka nájdeme na sociálnych sieťach za pár sekúnd a ak ju systém nedokáže odlíšiť od skutočnej osoby, útočník sa prihlási namiesto nej. Správa Agentúry Európskej únie pre kybernetickú bezpečnosť [1] uvádza takéto podvrhy – fotografie, videá prehrávané na displeji či masky – medzi hlavnými hrozbami overovania totožnosti na diaľku.

Samotné porovnanie dvoch tvárí teda nestačí. Systém musí okrem otázky „je to tá istá osoba?“ zodpovedať aj otázku „je pred kamerou naozaj živý človek?“. Práve tejto oblasti, odhaľovaniu podvrhov pred kamerou, sme sa v projekte venovali.

Cieľom práce bolo navrhnúť, naprogramovať a otestovať webový systém, ktorý používateľa prihlási iba pomocou tváre z bežnej webkamery a zároveň sa nedá oklamať fotografiou, displejom ani vopred nahraným videom. Nechceli sme sa spoľahnúť na jedinú techniku, preto systém kombinuje viac vrstiev ochrany: kontrolu kvality snímky, neurónovú sieť na rozpoznanie podvrhu, náhodnú výzvu na pohyb hlavy a kontrolu, že sa osoba počas snímania nezmenila. Hotový systém je verejne nasadený a jeho zdrojový kód je dostupný na GitHube.

Kapitola 2

Analýza problematiky

2.1 Ako funguje rozpoznávanie tváre

Rozpoznávanie tváre prebieha v niekoľkých krokoch. Najprv treba tvár v obraze nájsť. Detektor vráti jej polohu a niekoľko orientačných bodov – typicky stredy očí, špičku nosa a kútiky úst. Moderné detektory sú pritom veľmi malé; YuNet má menej ako sto tisíc parametrov a na bežnom procesore zvládne detekciu za niekoľko milisekúnd [2]. Podľa orientačných bodov sa tvár zarovná do jednotnej polohy a veľkosti, aby porovnanie neovplyvnilo, či je hlava mierne naklonená alebo ďalej od kamery.

Zarovnaný výrez tváre spracuje neurónová sieť a vytvorí z neho vektor príznakov, akýsi číselný „odtlačok“ tváre. Dobrý vektor má dve vlastnosti: dve fotky toho istého človeka dávajú podobné vektory aj pri inom svetle či výraze a fotky rôznych ľudí dávajú vektory, ktoré sú od seba ďaleko. Podobnosť sa najčastejšie meria uhlom medzi vektormi a o zhode rozhodne prah. Systém pritom môže pracovať v dvoch režimoch. Pri *overení* (1:1) používateľ tvrdí, kto je, a systém to iba potvrdí porovnaním s jedným uloženým vzorom. Pri *identifikácii* (1:N) systém hľadá najpodobnejší vzor v celej databáze, takže s rastúcim počtom používateľov rastie aj riziko zámeny.

To, ako dobre vektory oddeľujú ľudí, určuje hlavne spôsob trénovania siete. Metóda ArcFace pri trénovaní pridáva medzi osoby uhlovú rezervu, takže sieť sa musí naučiť vektory jednej osoby zhlukovať tesnejšie, než by bolo inak potrebné [3]. AdaFace túto rezervu mení podľa kvality obrázka – pri rozmazaných alebo tmavých snímkach je miernejšia, aby sa sieť neučila z nekvalitných dát zlé vzory [4]. SFace, ktorý používame v našom systéme, rieši podobný problém tak, že silu, ktorou sa vektory priťahujú a odpudzujú, obmedzuje sigmoidnou funkciou [5].

2.2 Kvalita biometrickej vzorky

Aj najlepší model zlyhá, ak dostane zlú snímku. Rozmazaná, tmavá, príliš malá alebo silno otočená tvár zvyšuje počet odmietnutých oprávnených používateľov a niekedy sa tvár nepodarí ani nájsť. Kvalitu sa preto oplatí kontrolovať ešte pred porovnaním a používateľovi povedať, čo má zlepšiť. Prehľad metód hodnotenia kvality [6] chápe kvalitu ako užitočnosť snímky pre rozpoznávanie, nie ako jej estetiku – pekná, ale z profilu odfotená tvár je pre systém horšia ako obyčajná fotka spredu z webkamery. Norma ISO/IEC 29794-5 z roku 2025 stanovuje, ako merať jednotlivé vlastnosti fotografie tváre, napríklad ostrosť, osvetlenie, polohu hlavy či otvorené oči, a rozlišuje použitie pri fotografiách do dokladov, pri registrácii a pri bežnom overovaní [7].

2.3 Podvrhy pred kamerou

Pri útoku podvrhom útočník ukáže kamere niečo, čo má systém považovať za tvár inej osoby, alebo sa snaží skryť vlastnú identitu. Najjednoduchší podvrh je vytlačená fotografia, prípadne ohnutá alebo s vystrihnutými očami, aby pôsobila živšie. Častý je aj útok, pri ktorom útočník ukáže fotografiu alebo video na displeji mobilu či tabletu. Náročnejšie sú papierové, silikónové alebo 3D tlačené masky [8]. Pri hodnotení systému sa každý druh podvrhu sleduje zvlášť, pretože proti každému pomáhajú iné vlastnosti obrazu.

Od podvrhov pred kamerou treba odlíšiť útoky, pri ktorých útočník kameru úplne obíde a pošle do systému podvrhnutý obraz priamo, napríklad cez virtuálnu kameru alebo upravenú aplikáciu. Takýto obraz nemusí mať žiadne fyzické stopy podvrhu, preto ho rozpoznanie podvrhu z obrazu samo nezachytí. Európska agentúra pre kybernetickú bezpečnosť ich preto uvádza ako samostatnú kategóriu hrozieb a odporúča ich riešiť ďalšími opatreniami, napríklad overením zariadenia [1].

2.4 Odhaľovanie podvrhov

Metódy odhaľovania podvrhov sa delia na pasívne a aktívne. Pasívne metódy skúmajú samotný obraz a hľadajú stopy podvrhu. Staršie prístupy využívali ručne navrhnuté znaky textúry, dnes sa takmer výhradne používajú hlboké neurónové siete, ktoré sa tieto stopy naučia z dát – napríklad textúru papiera, vlnovité pruhy vzniknuté snímaním displeja, odlesky alebo okraje fotografie [9]. Ich výhodou je, že používateľ nemusí nič robiť. Nevýhodou je, že model vie dobre rozpoznať iba to, čo videl pri trénovaní.

Práve schopnosť fungovať v nových podmienkach je hlavným otvoreným problémom. Model natrénovaný na jednej databáze často zlyhá pri inej kamere, inom osvetlení alebo novom druhu podvrhu. Výskum sa preto zameriava na metódy, ktoré lepšie

oddelia živé tváre od podvrhov aj v nových podmienkach [10], alebo využívajú veľké predtrénované modely spájajúce obraz a text [11]. Súťaže na rozsiahlych dátach z reálneho sveta zároveň ukazujú, že výsledky z laboratórnych databáz sa do praxe prenášajú len čiastočne [12].

Aktívne metódy naopak žiadajú od používateľa spoluprácu – má žmurknúť, usmiať sa alebo otočiť hlavu určeným smerom. Statická fotografia takúto akciu nevykoná a ak je poradie akcií náhodné, nepomôže ani vopred nahrané video. Cenou je o niečo dlhšie a menej pohodlné prihlásenie. V praxi sa preto oba prístupy často kombinujú, čo je aj prístup nášho systému.

2.5 Ako sa meria úspešnosť

Pri rozpoznávaní tváre sa systém môže pomýliť dvoma spôsobmi: prijme cudziu osobu, alebo odmietne oprávneného používateľa. Obe chyby závisia od prahu – prísnejší prah znižuje počet prijatých cudzích osôb, ale zvyšuje počet odmietnutých oprávnených. Systémy sa preto často porovnávajú v bode, v ktorom sú obe chyby rovnako časté, alebo pomocou krivky, ktorá ukazuje celý tento kompromis naraz. Pre bezpečnostné aplikácie je dôležité aj to, koľko oprávnených používateľov systém odmietne, keď sa nastaví tak, aby cudziu osobu prijal len veľmi zriedka.

Pri odhaľovaní podvrhov definuje spôsob merania norma ISO/IEC 30107-3 [13]. Sleduje sa podiel útokov, ktoré systém nesprávne prijal ako živú tvár – počíta sa zvlášť pre každý druh podvrhu a rozhodujúci je najhorší z nich. Druhou mierou je podiel skutočných používateľov, ktorých systém nesprávne označil za podvrh. V literatúre sa často uvádza aj priemer oboch hodnôt, norma ho však neodporúča, pretože skrýva, či systém zlyháva v bezpečnosti alebo v pohodlí [14]. Vhodnejšie je uvádzať, koľko živých používateľov systém odmietne pri pevne zvolenom podiele prijatých útokov, napríklad 5 %.

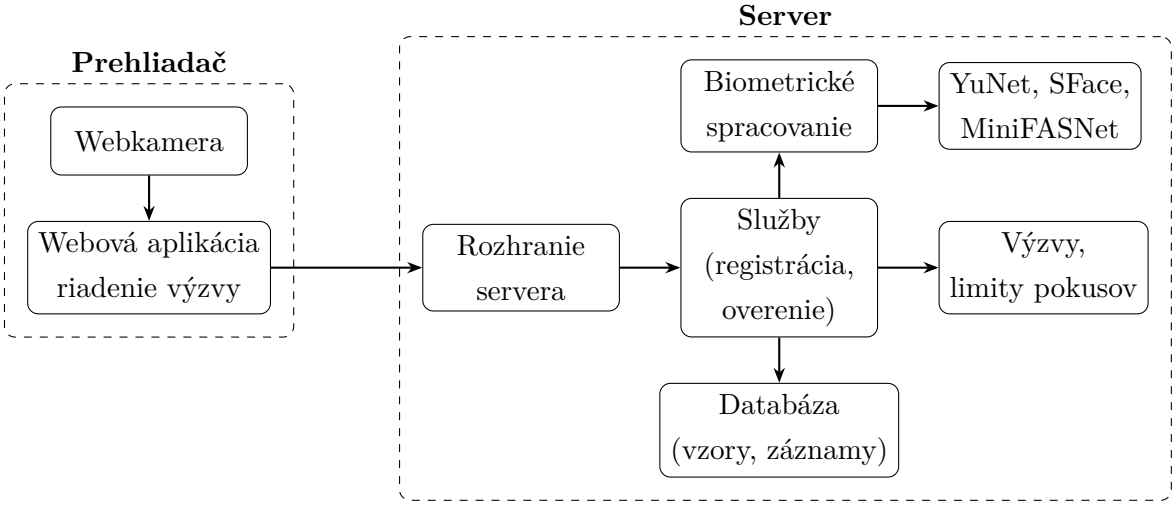
Kapitola 3

Návrh riešenia

Cieľom praktickej časti bolo vytvoriť funkčný webový systém, ktorý používateľa prihlási iba pomocou tváre snímanej bežnou webkamerou a ktorý zároveň odolá najčastejším podvrhom – fotografii, displeju s fotografiou alebo videom a pokusu o zámenu osoby počas snímania. Kapitola opisuje architektúru, spracovanie snímok a bezpečnostný návrh. Podrobnosti implementácie nasledujú v kapitole 4.

3.1 Architektúra

Systém sa skladá z klienta a servera (obr. 3.1). Klient je webová aplikácia v jazyku TypeScript s knižnicou React, ktorá ovláda webkameru, zobrazuje pokyny a odosiela snímky na server. Server je napísaný v jazyku Python s rámcom FastAPI a obsahuje celé biometrické spracovanie. Všetky rozhodnutia o živosti a zhode robí server – kód v prehliadači môže útočník ľubovoľne upraviť, preto mu nemožno dôverovať. Trvalé dáta sú v relačnej databáze (SQLite pri vývoji, PostgreSQL v prevádzke), krátkodobé údaje (jednorazové výzvy, počítadlá pokusov) v pamäti servera alebo v databáze Redis.



Obr. 3.1: Architektúra systému

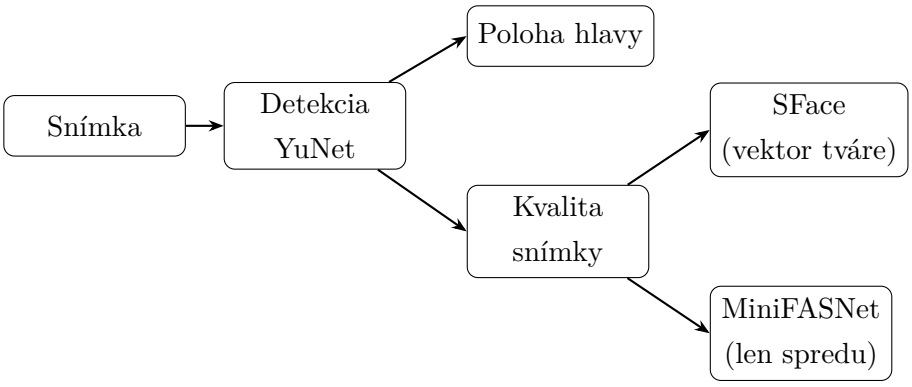
Serverová časť je rozdelená do vrstiev (tab. 3.1). Biometrické súčasti sú oddelené od zvyšku systému – detektor tváre, model na porovnávanie aj detektor podvrhu možno vymeniť bez zmeny ostatného kódu a v testoch ich nahradiť jednoduchými náhradami.

Tabuľka 3.1: Vrstvy serverovej časti

Vrstva	Úloha
Rozhranie	prijímanie požiadaviek, kontrola vstupov, overenie prihlásenia
Služby	registrácia, overenie, záznamy pokusov, dočasné zablokovanie účtu
Biometria	detekcia, kvalita, živosť, porovnanie, rozhodnutie
Infraštruktúra	databáza, šifrovanie, nastavenia

3.2 Spracovanie snímok

Každá snímka prechádza rovnakým spracovaním (obr. 3.2). Najprv detektor YuNet [2] nájde tváre a päť orientačných bodov (stredy očí, špička nosa, kútiky úst). Z orientačných bodov sa hneď vypočíta poloha hlavy – aj vtedy, keď snímka nesplní požiadavky na kvalitu, pretože počas otáčania hlavy je obraz často mierne rozmazaný. Ak snímka kvalitu spĺňa, model SFace [5] z nej vytvorí vektor so 128 číslami a pri snímkach spredu dvojica modelov MiniFASNet odhadne pravdepodobnosť, že ide o živú tvár.



Obr. 3.2: Spracovanie jednej snímky

Rozhodnutie sa však nerobí na základe jednej snímky, ale celého pokusu o prihlásenie. Ten tvorí postupnosť snímok zachytených počas jednej náhodnej výzvy. Server ho vyhodnotí v piatich krokoch a pri prvom neúspešnom kroku ho zamietne s konkrétnym dôvodom:

1. **Kvalita** – medzi snímkami musí byť aspoň jedna použiteľná snímka tváre spredu.
2. **Rozpoznanie podvrhu z obrazu** – snímky spredu musia mať v priemere skóre živosti aspoň 0,50 a žiadna z nich nesmie mať menej ako 0,20.

3. **Výzva na pohyb hlavy** – v každom kroku výzvy musí byť vidieť požadovaný pohyb.

4. **Stále tá istá osoba** – každá snímka musí byť dostatočne podobná snímkam z úvodu pokusu, aby sa osoba nemohla počas snímania vymeniť.

5. **Porovnanie** – tvár sa porovná s uloženým vzorom používateľa (alebo so všetkými vzormi pri prihlásení bez mena); zhoda nastane pri podobnosti aspoň 0,40.

Rozpoznanie podvrhu sa počíta iba na snímkach spredu, pretože modely MiniFASNet boli trénované na tvárach otočených do kamery a pri otočenej hlave dávajú zbytočne nízke skóre. Hranicu 0,50 sme zvolili na základe merania v kapitole 5. Vzor tváre vznikne spriemerovaním vektorov zo všetkých snímok spredu, čím sa zmiernia náhodné rozdiely medzi jednotlivými snímkami. Prah 0,40 je mierne prísnejší ako hodnota, ktorú pre model SFace odporúčajú jeho autori [17]; meranie na databáze LFW ukázalo, že pri ňom nevznikla ani jedna falošná zhoda.

3.3 Výzva na pohyb hlavy

Rozpoznanie podvrhu z obrazu sa učí z dát a jeho úspešnosť v nových podmienkach (iná kamera, iné osvetlenie) nie je zaručená [10]. Preto ho dopĺňa výzva na pohyb hlavy. Pri každom pokuse sa používateľ najprv pozrie do kamery a potom urobí dva pohyby, ktoré server náhodne vyberie zo štyroch možností: otočiť hlavu doľava, doprava, pozrieť sa hore alebo dole. Vznikne tak 12 možných poradí. Výzva platí 90 s a dá sa použiť iba raz. Statická fotografia nemôže vykonať pohyb a vopred nahrané video nepozná náhodné poradie.

Polohu hlavy systém odhadne z piatich bodov tváre: z toho, ako ďaleko je nos od stredu medzi očami. Keď človek otočí hlavu do strany, nos sa v obraze posunie vodorovne; keď sa pozrie hore alebo dole, nos sa priblíži k očiam alebo k ústam. Naklonenie hlavy do strany pritom výsledok neovplyvní.

Prvý krok výzvy (pohľad do kamery) určí, ako vyzerá poloha hlavy daného človeka, keď pozerá rovno. Ostatné kroky sa hodnotia ako zmena oproti nej – tým nezáleží na tvare tváre ani na tom, že kamera nie je presne pred používateľom. Krok je splnený, ak aspoň dve snímky ukazujú dostatočne veľký pohyb v správnom smere.

Prvá verzia klienta snímala každý krok pevne stanovený čas. Ak používateľ začal pohyb neskôr, v odoslaných snímkach ho nemuselo byť dosť a krok zlyhal, hoci ho používateľ vykonal. Výzvu sme preto prerobili tak, aby sa prispôsobila používateľovi: klient počas kroku posiela serveru aj malé náhľadové snímky, server vráti aktuálnu polohu hlavy a keď pohyb dosiahne hranicu, klient krok krátko nato ukončí (najneskôr po 5 s). Na server sa potom pošlú najmä snímky z okamihu pohybu. Toto meranie slúži

iba na navádzanie používateľa – konečné rozhodnutie urobí server znova zo všetkých odoslaných snímok, takže upravený klient nemôže výzvu obísť.

3.4 Bezpečnostný návrh

Tabuľka 3.2 sumarizuje uvažované hrozby a zodpovedajúce protiopatrenia. Rozdelenie útokov vychádza z normy ISO/IEC 30107-3 [13] a zo správy [1].

Tabuľka 3.2: Hrozby a protiopatrenia

Hrozba	Protiopatrenie
Vytlačená fotografia	MiniFASNet (textúra, okraje papiera); fotografia nevykoná pohyb
Fotografia alebo video na displeji	MiniFASNet (pruhy a rám displeja); náhodné poradie pohybov
Nahrávka s pohybmi hlavy	náhodná jednorazová výzva s krátkou platnosťou
Zámena osoby počas snímania	porovnanie všetkých snímok so vzorom z úvodu pokusu
Opakované odoslanie zachytenej požiadavky	výzva sa po použití okamžite zmaže
Skúšanie veľa pokusov za sebou	zablokovanie účtu po 5 neúspechoch za 15 min, obmedzenie počtu požiadaviek z jednej adresy, skóre sa používateľovi nevracajú
Zisťovanie, či účet existuje	neznámy používateľ dostane rovnakú odpoveď ako nezhoda tváre
Únik databázy	vzory sú zašifrované, kľúč nie je uložený v databáze
Registrácia jednej osoby pod viacerými menami	pri registrácii sa tvár hľadá medzi všetkými vzormi
Podvrhnutý obraz cez virtuálnu kameru	iba čiastočne (rozpoznanie z obrazu, výzva); úplná ochrana vyžaduje overenie zariadenia

Ochrana uložených vzorov je navrhnutá s ohľadom na to, že biometrický údaj nemožno po úniku zmeniť ako heslo [15]. Systém preto neukladá fotografie, vzor šifruje a umožňuje používateľovi kedykoľvek vymazať účet aj vzor. Každý pokus o prihlásenie do účtu – aj zamietnutý pre podvrh – sa zobrazí v histórii jeho vlastníka, takže používateľ vidí, ak sa niekto pokúšal prihlásiť namiesto neho.

3.5 Ochrana biometrických údajov

Biometrické údaje, ktoré slúžia na jednoznačnú identifikáciu osoby, patria podľa nariadenia Európskej únie o ochrane osobných údajov medzi osobitné kategórie osobných

údajov a ich spracovanie vyžaduje výslovný súhlas. Na rozdiel od hesla sa tvár po úniku nedá zmeniť, preto treba chrániť aj uložené vzory. Od ochrany sa očakáva, že z uloženého vzoru nepôjde zrekonštruovať pôvodnú tvár, že vzory z rôznych systémov sa nebudú dať prepojiť a že kompromitovaný vzor pôjde nahradiť novým. Používajú sa na to napríklad zrušiteľné biometrické vzory, biometrické šifrovacie schémy alebo šifrovanie, v ktorom možno počítať priamo so zašifrovanými dátami [15]. Od roku 2024 platí v Európskej únii aj akt o umelej inteligencii, ktorý systémy biometrickej identifikácie na diaľku zaraďuje medzi vysokorizikové. Výnimkou je biometrické overenie, ktorého jediným účelom je potvrdiť, že osoba je tá, za ktorú sa vydáva [16].

Kapitola 4

Implementácia

4.1 Použité technológie

Tabuľka 4.1: Použité technológie

Oblasť	Technológia
Server	Python 3.12, FastAPI, Pydantic, Uvicorn
Databáza	SQLAlchemy 2, Alembic (zmeny schémy), SQLite / PostgreSQL
Biometria	OpenCV (YuNet [2], SFace [5]), ONNX Runtime (MiniFASNet [18])
Bezpečnosť	PyJWT (prístupové tokeny), cryptography (šifrovanie vzorov)
Klient	TypeScript, React 19, React Router, Vite
Kvalita kódu	pytest, Ruff, mypy, ESLint, Vitest, GitHub Actions
Nasadenie	Docker, nginx, Render (server), Vercel (klient)

Všetky neurónové siete sú predtrénované a voľne dostupné, stiahnu sa jedným skriptom. Spolu majú približne 42 MB a bežia na bežnom procesore bez grafickej karty.

4.2 Detekcia tváre a kontrola kvality

Detektor YuNet sa volá cez knižnicu OpenCV. Pre každú tvár vráti jej polohu, päť orientačných bodov a skóre istoty. Ak je v obraze viac tvárí, pracuje sa s najväčšou.

Kontrola kvality je inšpirovaná normou ISO/IEC 29794-5 [7], ale je zjednodušená na rýchle a ľahko vysvetliteľné pravidlá:

- v zábere nesmie byť ďalšia tvár väčšia ako 15 % plochy hlavnej tváre,
- kratšia strana tváre musí mať aspoň 80 obrazových bodov,
- tvár musí byť dostatočne ostrá (meria sa, ako výrazne sa v obraze menia jasy susedných bodov),

- priemerný jas tváre musí byť medzi 40 a 225 (na stupnici 0–255).

Výsledkom je zoznam problémov, ktoré klient zobrazí ako krátku radu („Je príliš tma“). Rovnaká kontrola je dostupná aj samostatne a klient ju volá počas nastavovania tváre; okrem problémov vracia aj aktuálnu polohu hlavy. Prvá verzia mala pravidlá prísnejšie (90 bodov, vyššia ostrosť, jas od 50). Bežné kamery v notebookoch však pri horšom osvetlení dávajú tmavší a menej ostrý obraz, preto sme ich zmiernili.

4.3 Rozpoznanie podvrhu z obrazu

Použité sú dva modely MiniFASNet z projektu Silent-Face-Anti-Spoofing [18]. Každý z nich dostane výrez tváre spolu s časťou okolia, aby videl aj rám displeja alebo okraj papiera – prvý model užší, druhý širší. Oba vrátia pravdepodobnosť, že ide o živú tvár, a výsledné skóre je ich priemer.

4.4 Výzva a snímanie

Výzva sa uloží pod náhodným identifikátorom s platnosťou 90 s. Pri overení sa z úložiska v jednom kroku prečíta a zmaže, takže tú istú výzvu nemožno použiť dvakrát. Overuje sa aj účel výzvy – výzva vydaná na prihlásenie nemôže byť použitá na registráciu.

Na strane klienta každých 220 ms skopíruje aktuálny snímok z videa, zmenší ho na šírku 512 bodov a uloží ako komprimovaný obrázok. Úvodný krok (pohľad do kamery) trvá 1,6 s. V krokoch s pohybom klient zároveň posiela náhľady na kontrolu kvality a z vrátenej polohy hlavy počíta, koľko z požadovaného pohybu už používateľ urobil. Tento podiel sa zobrazuje ako vyplnenie prstenca okolo náhľadu kamery. Keď pohyb dosiahne hranicu, krok sa krátko nato ukončí, inak najneskôr po 5 s. Z každého kroku sa na server pošle najviac 10 snímok: prednostne tie z okamihu, keď bol pohyb rozpoznaný, a zvyšok rovnomerne z celého kroku. V prvej verzii sa posielalo len 10 posledných snímok; ak sa používateľ po otočení hneď vrátil do stredu, pohyb v nich chýbal a krok zlyhal.

Server pre každú snímku vypočíta polohu hlavy a zmenu oproti neutrálnej polohe v smere požadovaného pohybu. Ak niektorý krok neuspeje, odpoveď obsahuje jeho názov a klient používateľovi presne povie, ktorý pohyb nerozpoznal („Nerozpoznali sme otočenie hlavy doprava“). Do záznamu na serveri sa ukladá aj počet snímok v každom kroku a najväčší nameraný pohyb, čo pomáha pri ladení hraníc.

4.5 Registrácia, overenie a identifikácia

Všetky operácie majú rovnaký priebeh: spotrebovanie výzvy, kontrola, že snímky pokrývajú všetky kroky, načítanie obrázkov s obmedzením veľkosti, vyhodnotenie pokusu a nakoniec akcia podľa operácie:

- **registrácia** – kontrola, či meno nie je obsadené, vyhľadanie tváre medzi existujúcimi vzormi (jedna osoba sa nemôže zaregistrovať dvakrát), uloženie používateľa a zašifrovaného vzoru;
- **overenie podľa mena** – kontrola dočasného zablokovania, porovnanie so vzorom používateľa; neexistujúci používateľ dostane rovnakú chybu ako nezhoda;
- **prihlásenie bez mena** – porovnanie so všetkými vzormi aktívnych používateľov a výber najlepšej zhody nad prahom;
- **aktualizácia vzoru** – nový vzor sa uloží, iba ak sa zhoduje s pôvodným, aby ho nemohol vymeniť niekto, kto získal prístup k účtu.

Každý pokus sa zapíše do záznamu (operácia, výsledok, dôvod zamietnutia, skóre zhody a živosti, výsledok výzvy, počet snímok, čas spracovania, adresa). Záznam sa uloží samostatne, takže zostane zachovaný aj pri neúspechu. Z týchto záznamov sa počíta aj dočasné zablokovanie účtu.

4.6 Bezpečnosť a ochrana údajov

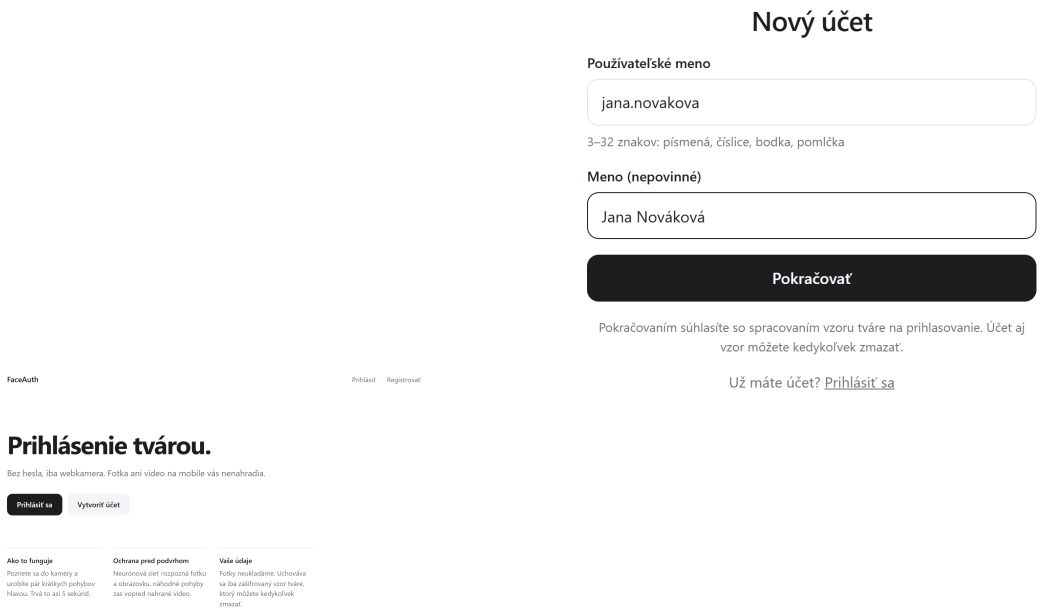
- **Šifrovanie vzorov** – vektor tváre sa pred uložením zašifruje, pričom šifrovanie zároveň odhalí akúkoľvek zmenu zašifrovaných dát. Kľúč je uložený v nastaveniach servera, nie v databáze. Vzor je viazaný na verziu modelu, po výmene modelu sa starý vzor nepoužije.
- **Prihlásenie** – po úspešnom overení dostane klient podpísaný prístupový token platný 30 minút.
- **Ochrana proti zneužitiu** – obmedzenie počtu požiadaviek z jednej adresy, limit veľkosti požiadavky (20 MB), jednej snímky (2 MB) a počtu snímok (50); obrázky sa zmenšia na najviac 1280 bodov.
- **Prevádzkový režim** – server odmietne štartovať bez nastavených tajných kľúčov; v odpovediach sa nevracajú skóre, aby útočník nemohol vstup postupne ladiť podľa nich; vypnutá je aj verejná dokumentácia rozhrania.
- **Klient** – prehliadač smie načítať obsah iba z vlastnej domény, stránku nemožno vložiť do inej stránky a token zanikne zatvorením karty.

- **Osobné údaje** – používateľ môže vymazať účet aj vzor; pri registrácii je informovaný o spracovaní biometrického údaja.

4.7 Klientska aplikácia

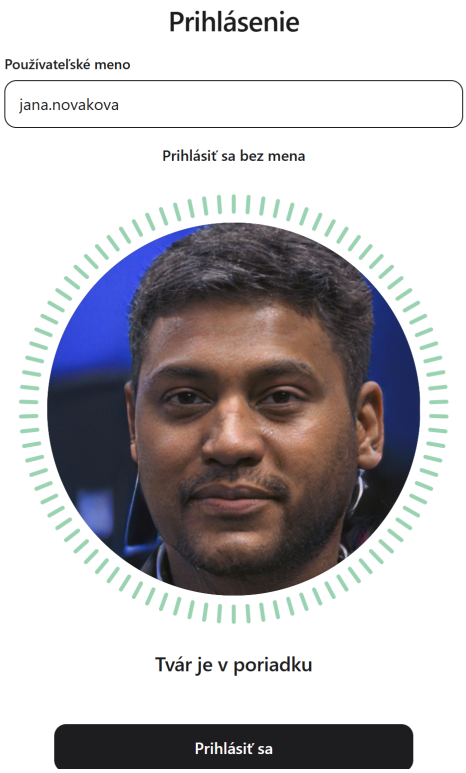
Pri návrhu rozhrania sme sa inšpirovali existujúcimi aplikáciami na prihlásenie tvárou, napríklad nastavením Face ID v systéme iOS: veľký okrúhly náhľad kamery, okolo neho prstenec z čiarok, ktorý sa postupne vypĺňa, a pod ním jedna krátka veta s pokynom. Rozhranie je zámerne jednoduché – bez vysvetľujúcich odsekov, s jedným hlavným tlačidlom na obrazovke. Ak je tvár v kruhu v poriadku, prstenec sa zafarbí nazeleno (obr. 4.2). Počas kroku s pohybom sa vo vnútri kruhu zobrazí šípka v smere pohybu (obr. 4.3a) a po neúspechu sa prstenec zafarbí načerveno a pod ním je dôvod zamietnutia (obr. 4.3b). Náhľad je zrkadlený, aby pokyn „doľava“ zodpovedal smeru, ktorý používateľ vidí.

Snímky obrazoviek v tejto kapitole boli vytvorené s virtuálnou kamerou, ktorej obraz tvorila verejne dostupná, umelo vygenerovaná fotografia tváre (voľné dielo). Ide teda zároveň o ukážku útoku statickým obrázkom – systém ho podľa očakávania zamietol, pretože obraz sa počas výzvy nepohol.

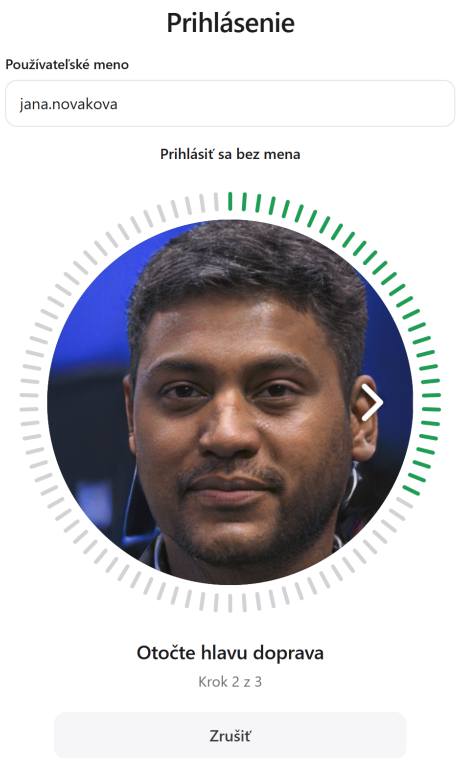


(a) Úvodná stránka (b) Registrácia – prvý krok

Obr. 4.1: Úvodná stránka a registrácia



Obr. 4.2: Prihlásenie – tvár je v kruhu a spĺňa požiadavky na kvalitu

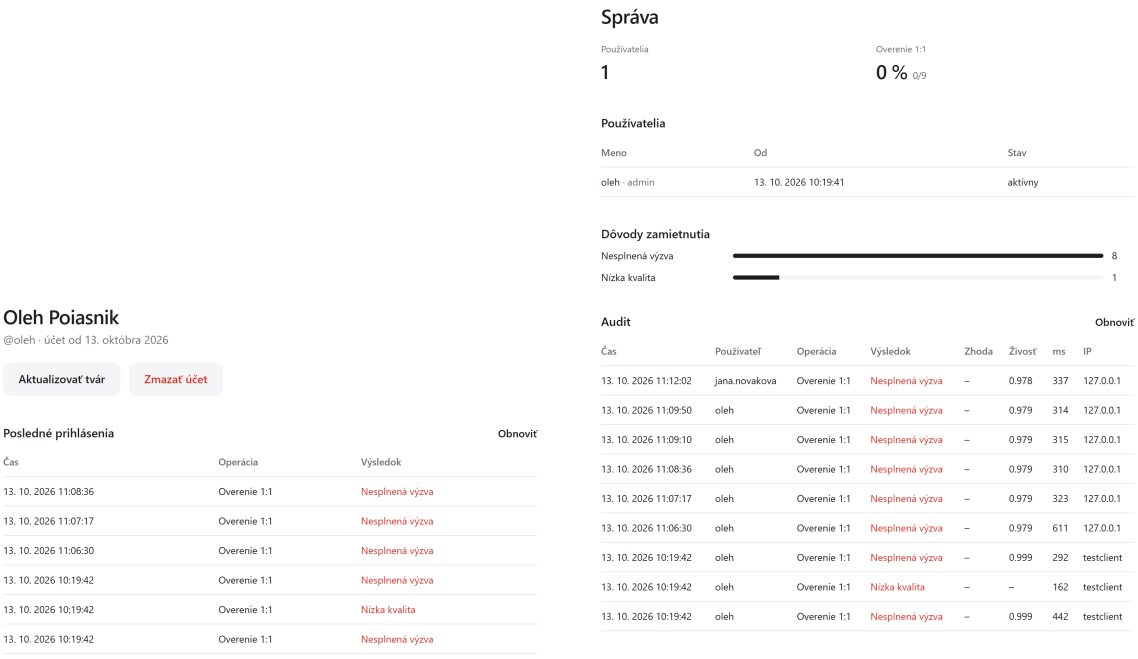


(a) Krok výzvy „Otočte hlavu doprava“



(b) Zamietnutie statického obrázka

Obr. 4.3: Výzva na pohyb hlavy počas prihlásenia



(a) Účet s históriou pokusov (b) Správa systému

Obr. 4.4: Používateľský účet a správa systému

Snímanie v klientovi zabezpečujú tri časti: spúšťanie kamery so zrozumiteľnými chybovými hláseniami, priebežná kontrola kvality pred začiatkom a riadenie samotnej výzvy. Pri testovaní sme v spúšťaní kamery našli chybu: ak sa kamera spustila dvakrát rýchlo po sebe (napríklad pri rýchlom prechode medzi stránkami), druhé spustenie prerušilo prvé a aplikácia nesprávne hlásila, že kamera nie je dostupná. Oprava každé spustenie očísluje a výsledky starších spustení zahodí. Chyby zo servera sa prekladajú na krátke slovenské hlásenia.

4.8 Nasadenie

Server aj klient sa dajú spustiť v kontajneroch Docker. Lokálne sa celý systém spustí jedným príkazom: webový server nginx poskytuje súbory klienta a požiadavky na rozhranie posiela ďalej na server, ktorý pri štarte pripraví databázu. Verejná inštancia beží na službách Render (server s databázou PostgreSQL) a Vercel (klient). Vercel posiela požiadavky na rozhranie ďalej na server, takže prehliadač komunikuje iba s jednou adresou.

- Aplikácia: `https://face-auth-antispoofing.vercel.app`
- Repozitár: `https://github.com/opoiasnik/face-auth-antispoofing`

Bezplatná inštancia servera má k dispozícii len malý zlomok výkonu jedného jadra procesora. Spracovanie prihlásenia, ktoré na notebooku trvá desatiny sekundy, tam trvalo desiatky sekúnd. Preto klient posiela menšie snímky a server počíta vektor tváre pri krokoch s pohybom len z niekoľkých vybraných snímok – na overenie, že ide stále o tú istú osobu, to stačí.

Kapitola 5

Testovanie a vyhodnotenie

Systém sme overili na štyroch úrovniach: (1) automatické testy, (2) presnosť rozpoznávania tváre na verejnej databáze LFW, (3) rozpoznávanie podvrhov na verejnej databáze CASIA-FASD a (4) testy celého systému cez jeho rozhranie. Rýchlosť sme merali samostatne. Na všetky merania sme napísali skripty, ktoré sú súčasťou repozitára a výsledky ukladajú ako tabuľky a grafy.

5.1 Ako počítame chyby

Rozpoznávanie tváre

Porovnávame dvojice fotografií tej istej osoby a dvojice rôznych osôb a pri zvolenom prahu podobnosti sledujeme dve chyby:

- **prijaté cudzie osoby** – koľko percent dvojíc rôznych osôb malo podobnosť aspoň na úrovni prahu, teda systém by ich považoval za tú istú osobu,
- **odmietnuté vlastné tváre** – koľko percent dvojíc tej istej osoby malo podobnosť pod prahom, teda systém by oprávneného používateľa nepustil.

Ďalej uvádzame prah, pri ktorom sú obe chyby rovnaké, podiel odmietnutých vlastných tvárí pri prahu, ktorý prijme najviac 1 % resp. 0,1 % cudzích osôb, a podiel fotografií, na ktorých sa tvár nepodarilo nájsť.

Rozpoznávanie podvrhov

Podľa normy ISO/IEC 30107-3 [13] sledujeme:

- **prijaté útoky** – koľko percent podvrhov daného druhu systém označil za živú tvár; ako celkovú hodnotu berieme najhorší druh podvrhu,

- **odmietnuté živé tváre** – koľko percent skutočných tvárí systém označil za podvrh.

Uvádzame aj podiel odmietnutých živých tvárí pri hranici, ktorá prijme najviac 5 % resp. 1 % útokov.

5.2 Automatické testy

Serverová časť má 51 automatických testov, ktoré prejdú 87 % jej kódu. Testy nahrádzajú neurónové siete jednoduchými náhradami: umelá snímka nesie v jednom bode informáciu o tom, komu patrí, ako je otočená hlava a či je živá. Vďaka tomu sa celý postup overuje cez skutočné rozhranie servera bez modelov a bez grafickej karty. Klient má 11 testov. Testy, kontrola kódu a zostavenie kontajnerov bežia automaticky pri každej zmene v službe GitHub Actions.

Tabuľka 5.1: Čo overujú automatické testy

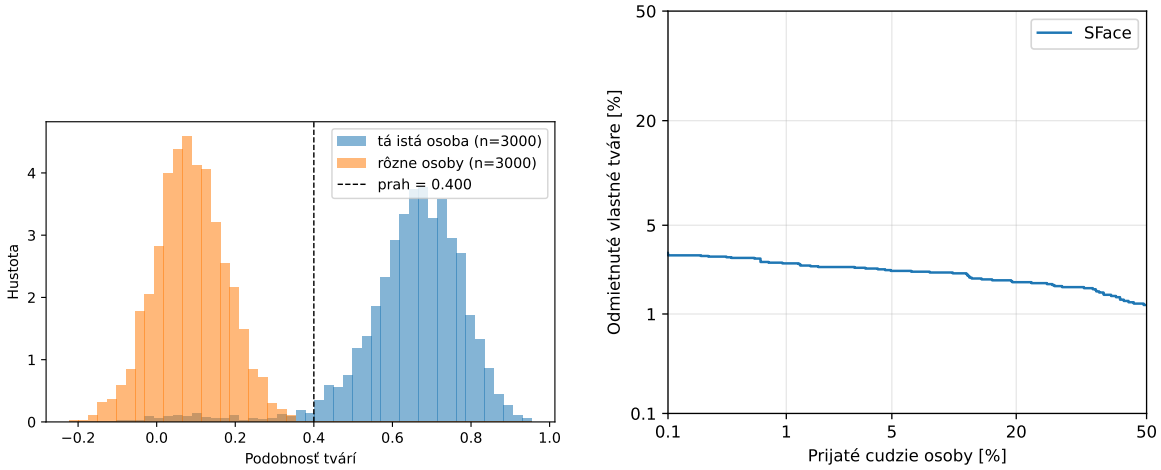
Oblasť	Overované správanie
Poloha hlavy	smer otočenia a sklonu, nezávislosť od naklonenia hlavy, chybné body, výpočet aj z rozmazanej snímky
Výzva	správny a nesprávny smer, príliš malý pohyb, málo snímok s tvárou, náhodnosť poradia
Výpočet chýb	podiely chýb, bod rovnakej chyby (aj porovnaním s teoretickou hodnotou)
Bezpečnosť	podpis a platnosť tokenu, šifrovanie vzorov, kontrola nastavení, obmedzenie počtu požiadaviek
Výzvy	jednorazové použitie, uplynutie platnosti, kontrola účelu
Celý postup	registrácia a overenie, cudzia osoba, neznámy používateľ, útok fotografiou, zámena osoby počas snímania, opakované použitie výzvy, chýbajúci krok, duplicitná tvár, prihlásenie bez mena, zablokovanie účtu, výmaz účtu, práva správcu, história zamietnutých pokusov
Klient	výpočet pohybu hlavy, výber snímok z kroku, preklad chybových hlásení

5.3 Presnosť rozpoznávania tváre

Model SFace sme vyhodnotili na databáze Labeled Faces in the Wild [19] podľa jej štandardného postupu – 6000 dvojíc fotografií, z toho 3000 dvojíc tej istej osoby a 3000 dvojíc rôznych osôb. Kontrolu kvality sme pri tomto meraní vypli, aby sme merali samotný model rozpoznávania. Tvár sa našla na všetkých 12 000 fotografiách. Výsledky sú v tabuľke 5.2 a na obr. 5.1.

Tabuľka 5.2: Rozpoznávanie tváre na databáze LFW (6000 dvojíc)

Nastavenie prahu	Prah	Prijaté cudzie [%]	Odmietnuté vlastné [%]
obe chyby rovnaké	0,266	2,47	2,47
prah použitý v systéme	0,400	0,00	3,90
najviac 1 % cudzích	0,294	1,00	2,63
najviac 0,1 % cudzích	0,339	0,10	3,03



(a) Rozdelenie podobnosti

(b) Kompromis medzi chybami

Obr. 5.1: Rozpoznávanie tváre na databáze LFW

Podobnosti dvojíc tej istej osoby a dvojíc rôznych osôb sa prekrývajú len málo. Pri použitom prahu 0,40 nevznikla v 3000 porovnaniach rôznych osôb ani jedna falošná zhoda, cenou je odmietnutie 3,9 % dvojíc tej istej osoby. Databáza LFW obsahuje fotografie z rôznych rokov, s rôznou polohou hlavy a osvetlením, čo je náročnejšia situácia ako prihlasovanie pred vlastnou webkamerou. Pri prihlasovaní sa navyše vzor počíta z viacerých snímok, čo náhodné výkyvy ďalej zmierňuje. Prah 0,40 preto považujeme za vhodný kompromis medzi bezpečnosťou a pohodlím.

5.4 Rozpoznávanie podvrhov z obrazu

Na vyhodnotenie sme použili testovaciu časť verejnej databázy CASIA-FASD [20], konkrétne 2408 snímok vybraných z jej videí. Databáza obsahuje živé tváre a tri druhy podvrhov (tab. 5.3). Snímky v použitej verzii databázy sú už orezané okolo tváre na 256×256 bodov, takže modely MiniFASNet nevidia celé okolie tváre, s ktorým počítajú. Výsledky sú preto skôr pesimistickým odhadom.

Tabuľka 5.3: Snímky použité na vyhodnotenie (CASIA-FASD, testovacia časť)

Trieda	Popis	Snímky
živá tvár	skutočná osoba pred kamerou	591
ohnutá fotografia	vytlačená fotografia, ohýbaná pred kamerou	712
vystrihnuté oči	vytlačená fotografia s vystrihnutými očami	536
video na displeji	video prehrávané na displeji	569

Pri pôvodnej hranici 0,70 boli podvrhy zachytené takmer úplne (prijatých najviac 0,93 %), no odmietnutých bolo 34 % snímok živých tvárí. Taká hranica by v praxi viedla k častému odmietaniu skutočných používateľov. Tabuľka 5.4 ukazuje, ako sa chyby menia s hranicou.

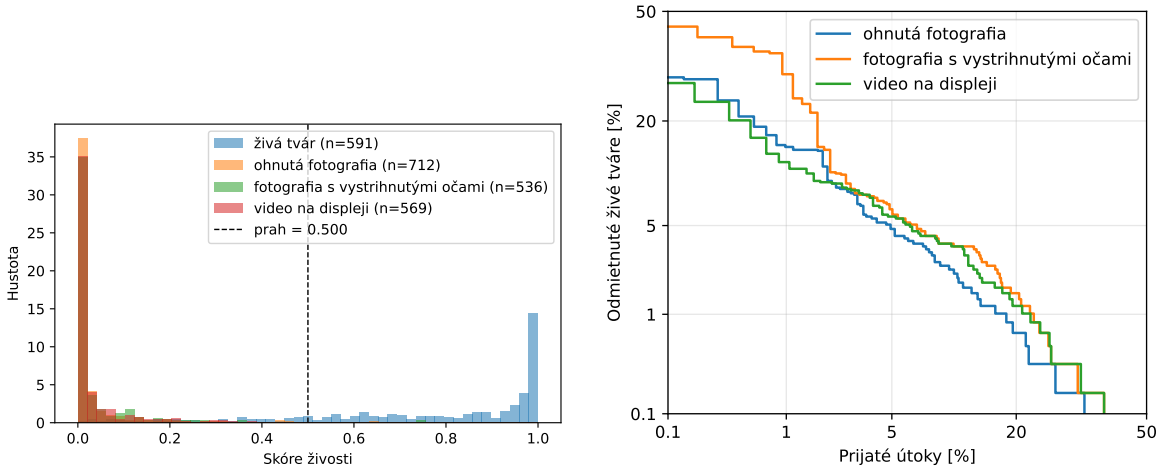
Tabuľka 5.4: Chyby rozpoznávania podvrhov pri rôznych hraniciach (jednotlivé snímky)

	Odmietnuté	Prijaté útoky [%]		
Hranica	živé [%]	ohnutá fotografia	vystrihnuté oči	video na displeji
0,20	5,58	3,93	5,97	5,62
0,30	8,63	2,67	2,99	2,64
0,40	12,86	1,83	2,05	0,88
0,50	18,10	0,70	1,68	0,53
0,60	25,21	0,28	1,12	0,18
0,70	34,35	0,00	0,93	0,00

Hranicu sme znížili na 0,50. Pri nej sa pri žiadnom druhu podvrhu neprijme viac ako 1,7 % snímok. Odmietnutie 18 % živých snímok sa týka jednotlivých snímok – pri prihlásení sa skóre priemeruje cez približne sedem snímok spredu, takže náhodne nízke skóre jednej snímky prihlásenie nezamietne. Podvrhy, ktoré by táto vrstva prepustila, musia navyše prejsť výzvou na pohyb hlavy. Výsledky pri hranici použitej v systéme sú v tabuľke 5.5.

Tabuľka 5.5: Rozpoznávanie podvrhov na databáze CASIA-FASD (hranica 0,50)

Ukazovateľ	Hodnota [%]
prijaté útoky – ohnutá fotografia	0,70
prijaté útoky – vystrihnuté oči	1,68
prijaté útoky – video na displeji	0,53
prijaté útoky – najhorší druh	1,68
odmietnuté živé tváre	18,10
bod, v ktorom sú obe chyby rovnaké	5,25
odmietnuté živé tváre pri 5 % prijatých útokov	5,58
odmietnuté živé tváre pri 1 % prijatých útokov	16,58



(a) Rozdelenie skóre živosti

(b) Kompromis medzi chybami

Obr. 5.2: Rozpoznávanie podvrhov na databáze CASIA-FASD

Z histogramu je vidieť, že skóre takmer všetkých podvrhov je blízko nuly a podvrhy sa líšia len v tom, ako často sa objaví výnimka. Najťažšie odhaliteľná je fotografia s vystrihnutými očami, pri ktorej sú v obraze skutočné oči útočníka. Živé tváre majú skóre rozložené širšie, čo súvisí s nižšou kvalitou videí v databáze a s orezaním okolia tváre.

5.5 Testy celého systému

Útok statickým obrázkom

Útok statickým obrázkom sme vyskúšali dvoma spôsobmi. V prvom sme do prehliadača podstrčili virtuálnu kameru, ktorej obraz tvorila umelo vygenerovaná fotografia tváre, a prešli sme bežným prihlásením cez webovú aplikáciu. Rozpoznanie podvrhu z obrazu

v tomto prípade obraz nezamietlo (skóre živosti 0,98) – obrázok vložený priamo do videa nemá žiadne stopy tlače ani displeja, ide teda v skutočnosti o obídenie kamery. Zachytila ho až výzva na pohyb hlavy, pretože tvár sa v žiadnom kroku nepohla (obr. 4.3b). Počas tvorby snímok obrazovky sme takto vykonali 6 pokusov a všetky boli zamietnuté pre nesplnenú výzvu.

V druhom teste sme ten istý obrázok poslali 30-krát priamo na server (prihlásenie bez mena), s drobným posunom a šumom medzi snímkami a so stratovou kompresiou podobne ako pri skutočnej kamere. Všetkých 30 pokusov zamietlo už rozpoznanie podvrhu z obrazu; priemerné skóre živosti pokusu bolo 0,25 (od 0,04 do 0,52). Oba testy ukazujú, prečo systém používa obe vrstvy: každá zachytila prípad, ktorý by druhá prepustila.

Tabuľka 5.6: Útok statickým obrázkom

Spôsob útoku	Pokusy	Zamietnuté	Vrstva, ktorá útok zachytila
Virtuálna kamera v prehliadači	6	6	výzva na pohyb hlavy
Priame poslanie na server	30	30	rozpoznanie podvrhu z obrazu

Test so živými používateľmi

Overenie celého systému zahŕňa prihlásenie registrovanej osoby, pokus o prihlásenie inej osoby a prezentačné útoky pomocou fotografie alebo videa. Tabuľka 5.7 uvádza navrhnuté scenáre a očakávané rozhodnutia systému. Výsledky týchto meraní nie sú súčasťou experimentálneho vyhodnotenia, preto z nich zatiaľ nemožno určiť úspešnosť prihlasovania ani odolnosť proti jednotlivým fyzickým útokom. Postup merania a spôsob zaznamenávania pokusov sú opísané v `docs/manual-test-protocol.md`.

Tabuľka 5.7: Scenáre testu so živými používateľmi

Scenár	Pokusy	Očakávané	Výsledok
Používateľ s menom	nezmerané	prijatie	nezmerané
Používateľ bez mena	nezmerané	prijatie	nezmerané
Iná osoba s menom obete	nezmerané	nezhoda	nezmerané
Vytlačená fotografia obete	nezmerané	zamietnutie	nezmerané
Fotografia na displeji	nezmerané	zamietnutie	nezmerané
Video obete s pohybmi hlavy	nezmerané	zamietnutie	nezmerané
Zámena osoby počas snímania	nezmerané	zmena osoby	nezmerané

5.6 Rýchlosť

Rýchlosť sme merali na notebooku s procesorom Intel Core i7-13650HX bez použitia grafickej karty, 200 opakovaní, na snímke s rozmermi 640 × 360 bodov.

Tabuľka 5.8: Čas spracovania jednej snímky (640 × 360 bodov) v milisekundách

Časť spracovania	Priemer	Medián	95 % meraní do
Detekcia tváre (YuNet)	4,76	4,65	5,50
Kontrola kvality	0,10	0,10	0,11
Poloha hlavy	0,01	0,01	0,01
Rozpoznanie podvrhu (MiniFASNet)	2,59	2,53	2,90
Vektor tváre (SFace)	3,98	3,95	4,38
Celá snímka	12,23	12,06	13,31

Jedno prihlásenie má najviac 27 snímok, jeho spracovanie na notebooku teda trvá približne 0,3 s. Pre porovnanie, pri snímke 1280 × 720 bodov trvá samotná detekcia 18 ms a celá snímka 26 ms, preto klient snímky pred odoslaním zmenšuje. Celkovú dobu prihlásenia (približne 5–7 s) určuje najmä čas, ktorý používateľ potrebuje na vykonanie pohybov. Na bezplatnej inštancii služby Render je spracovanie výrazne pomalšie a prvá požiadavka po dlhšej nečinnosti trvá až desiatky sekúnd, kým sa server spustí.

5.7 Obmedzenia experimentálneho vyhodnotenia

Výsledky rozpoznávania tváre, pasívnej detekcie podvrhov a merania latencie sú uložené v priečinku `report/results/`. Súbory `summary.json` obsahujú súhrnné ukazovatele a súbory `scores.csv` jednotlivé skóre. Tieto výstupy umožňujú overiť výpočet metrík bez uchovávania snímok tvárí alebo biometrických vzorov.

Vyhodnotenie rozpoznávania vychádza zo súhrnnej množiny 6000 dvojíc databázy LFW. Použitý skript nevykonáva samostatnú kalibráciu prahu v jednotlivých foldoch. Pracovné body odvodené z tejto množiny preto charakterizujú dostupnú vzorku a nepredstavujú nezávislé overenie kalibrácie. Nulový počet falošných zhôd v 3000 porovnaniach rôznych osôb zároveň nezaručuje nulovú chybovosť v prevádzke.

Pri vyhodnotení na databáze CASIA-FASD pochádza viac snímok z rovnakých videí. Výsledky jednotlivých snímok preto nemožno interpretovať ako výsledky nezávislých autentifikačných relácií. Prah 0,50 bol posudzovaný na rovnakej vzorke, čo obmedzuje závery o jeho správaní pri nových osobách, kamerách a svetelných podmienkach. Hodnoty BPCER20 a BPCER100 boli vypočítané zo spojených skóre všetkých

útokov, kým APCER pri systémovom prahu vyjadruje maximum cez jednotlivé druhy útokov.

Čas spracovania relácie približne 0,3 s je odhad odvodený z priemernej latencie jednej snímky a počtu najviac 27 snímok. Nezahŕňa prenos údajov, databázové operácie ani čas potrebný na vykonanie pohybov. Automatické testy overujú logiku aplikácie pomocou náhrad biometrických modelov. Testy so statickým obrázkom zase hodnotia konkrétny syntetický vstup. Ani jedna z týchto metód nenahrádza meranie úspešnosti celého systému s reálnymi používateľmi a fyzickými podvrhmi.

Kapitola 6

Príručka a dokumentácia

6.1 Archivácia a opakovateľnosť

Zdrojový kód, dokumentácia, vyhodnocovacie skripty aj táto správa sú v repozitári `https://github.com/opoiasnik/face-auth-antispoofing`. Aby sa dal projekt zopakovať, obsahuje:

- skript na stiahnutie modelov s kontrolnými súčtami,
- skripty na prípravu databázy – tabuľky sa vytvoria automaticky,
- presne uzamknuté verzie knižníc klienta,
- kontajnery Docker a súbor `docker-compose.yml` na spustenie jedným príkazom,
- automatické testy spúšťané pri každej zmene,
- vyhodnocovacie skripty, ktoré si samy stiahnu verejné dáta (LFW) alebo pracujú s priečinkom s jasne danou štruktúrou (CASIA-FASD, vlastné nahrávky).

Podrobná technická dokumentácia je v priečinku `docs/` repozitára: architektúra (`architecture.md`), popis rozhrania servera (`api.md`), príručka používateľa (`user-guide.md`) a postup vyhodnotenia (`evaluation.md`).

6.2 Inštalácia a spustenie

Spustenie na vlastnom počítači

Potrebné sú Python 3.11 alebo novší, Node.js 20 alebo novší a webkamera.

Listing 6.1: Spustenie servera

```
cd backend
python -m venv .venv
```

```
.venv/Scripts/activate        # Linux/macOS: source .venv/bin/activate
pip install -e ".[dev,eval]"
python scripts/download_models.py
uvicorn app.main:create_app --factory --port 8000
```

Listing 6.2: Spustenie klienta

```
cd frontend
npm ci
npm run dev                   # http://localhost:5173
```

Spustenie v kontajneroch

```
cp .env.example .env
docker compose up -d --build  # http://localhost:8080
```

Pri verejnom nasadení treba zapnúť prevádzkový režim, vygenerovať tajné kľúče a aplikáciu sprístupniť cez zabezpečené pripojenie – prehliadač inak nepovolí prístup ku kamere:

```
python -m app.cli generate-secrets   # vypíše tajné kľúče do súboru .env
FA_ENVIRONMENT=production            # zapne prevádzkový žreim
```

Vyhodnotenie

```
python -m evaluation.evaluate_recognition --lfw
python -m evaluation.evaluate_pad --dir data/pad
python -m evaluation.benchmark --image tvar.jpg --runs 200
python -m evaluation.audit_report
```

Nastavenia

Hranice a limity sa nastavujú premennými prostredia s predponou `FA_` (tab. 6.1).

Tabuľka 6.1: Najdôležitejšie nastavenia

Premenná	Predvolená	Význam
`FA_MATCHING__THRESHOLD`	0,40	prah podobnosti tvárí
`FA_PASSIVE_LIVENESS__THRESHOLD`	0,50	hranica skóre živosti
`FA_ACTIVE_LIVENESS__STEPS`	2	počet náhodných pohybov vo výzve
`FA_ACTIVE_LIVENESS__YAW_THRESHOLD`	0,20	najmenšie otočenie hlavy
`FA_ACTIVE_LIVENESS__PITCH_THRESHOLD`	0,07	najmenší pohyb hore alebo dole
`FA_CHALLENGE__ACTION_TIMEOUT_MS`	5000	najdlhšie trvanie kroku s pohybom
`FA_SECURITY__LOCKOUT_MAX_FAILURES`	5	neúspechy do zablokovania účtu
`FA_SECURITY__EXPOSE_SCORES`	true	vracanie skóre (pri nasadení vypnúť)
`FA_DATABASE_URL`	SQLite	pripojenie k databáze
`FA_REDIS_URL`	–	zdieľané výzvy pri viacerých procesoch

6.3 Príručka používateľa

Registrácia

1. Na stránke *Registrovať* zadajte používateľské meno (3–32 znakov: malé písmená, číslice, bodka, pomlčka, podčiarkovník), voliteľne meno a kliknite na *Pokračovať*.

2. Povoľte prístup ku kamere a umiestnite tvár do kruhu. Keď sa prstenec okolo kruhu zafarbí nazeleno a zobrazí sa „Tvár je v poriadku“, kliknite na *Začať*.

3. Pozrite sa do kamery a potom urobte pohyby podľa pokynu pod kruhom (napríklad „Otočte hlavu doľava“); smer ukazuje aj šípka v kruhu. Krok sa ukončí sám, keď systém pohyb rozpozná. Poradie pohybov je pri každom pokuse iné.

4. Po úspešnom overení sa vytvorí účet a používateľ je prihlásený.

Prihlásenie

Štandardne sa zadáva meno a systém porovná tvár iba s vaším vzorom. Odkaz *Prihlásiť sa bez mena* prepne na vyhľadanie iba podľa tváre. Postup snímania je rovnaký ako pri registrácii. Po piatich neúspešných pokusoch počas 15 minút sa účet dočasne zablokuje.

Riešenie problémov

Tabuľka 6.2: Časté hlásenia a ich riešenie

Hlásenie	Riešenie
Kamera nie je dostupná	povoľte kameru v nastaveniach stránky a kliknite na *Povoliť kameru*
Nevidíme vašu tvár / Podíďte bližšie	tvár do kruhu, bližšie ku kamere
Je príliš tma / Je príliš svetla	otočte sa k zdroju svetla, nesedte proti oknu
Nerozpoznali sme …	urobte uvedený pohyb výraznejšie, až keď sa zobrazí pokyn
Vyzerá to na fotografiu alebo obrazovku	nepoužívajte fotografiu ani displej; pri falošnom poplachu zlepšite osvetlenie
Tvár sa nezhoduje s účtom	zlepšite svetlo; pri zmene vzhľadu aktualizujte vzor v účte
Príliš veľa pokusov	počkajte 15 minút

Používateľský účet a správa

V účte je história všetkých pokusov o prihlásenie vrátane neúspešných, možnosť aktualizovať vzor tváre (nový vzor sa musí zhodovať s pôvodným) a natrvalo vymazať účet aj vzor (obr. 4.4). Rolu správcu prideľuje príkaz `python -m app.cli promote <meno>`. Správca vidí úspešnosť jednotlivých operácií, dôvody zamietnutí, zoznam používateľov (zablokovanie, odstránenie) a všetky záznamy pokusov.

6.4 Rozhranie servera

Tabuľka 6.3: Hlavné adresy rozhrania servera (predpona `/api/v1`)

Metóda	Cesta	Popis
POST	`/challenges`	vydanie jednorazovej výzvy
POST	`/biometrics/quality`	kvalita a poloha hlavy na jednej snímke
POST	`/enrollment`	registrácia
POST	`/auth/verify`	overenie podľa mena
POST	`/auth/identify`	prihlásenie bez mena
GET	`/users/me/attempts`	história vlastných pokusov
PUT	`/users/me/face`	aktualizácia vzoru
DELETE	`/users/me`	výmaz účtu a vzoru
GET	`/admin/stats`, `/admin/attempts`	štatistiky a záznamy (správca)

Úplný popis vrátane formátu chýb je v súbore `docs/api.md`.

Kapitola 7

Záver

V projekte sme navrhli, implementovali a nasadili webový systém na prihlasovanie tvárou s viacvrstvovou ochranou proti podvrhom. Systém tvár sníma bežnou webkamerou, všetky rozhodnutia robí na serveri a kombinuje kontrolu kvality snímky, rozpoznanie podvrhu z obrazu modelmi MiniFASNet, náhodnú výzvu na pohyb hlavy a kontrolu, že ide počas celého snímania o tú istú osobu. Tvár porovnáva modelom SFace a uložené vzory šifruje.

Meranie ukázalo, že rozpoznávanie tváre pri použitom prahu na databáze LFW neprijalo ani jednu cudziu osobu a odmietlo 3,9 % dvojíc tej istej osoby. Pri rozpoznávaní podvrhov na databáze CASIA-FASD meranie odhalilo, že pôvodná hranica 0,70 odmietala príliš veľa živých tvárí, preto sme ju znížili na 0,50; pri nej systém prijme najviac 1,7 % podvrhov jedného druhu. Pri teste statickým obrázkom sa ukázalo, že vrstvy sa dopĺňajú: obraz vložený cez virtuálnu kameru prešiel rozpoznaním z obrazu, ale zastavila ho výzva na pohyb hlavy, a naopak snímky poslané priamo na server zachytilo rozpoznanie z obrazu. Spracovanie jedného prihlásenia trvá na bežnom procesore približne 0,3 s.

Počas testovania sme na základe výsledkov upravili aj samotný systém: výzva sa namiesto pevného času prispôsobuje pohybu používateľa, na server sa posielajú snímky z okamihu pohybu, poloha hlavy sa počíta aj z rozmazaných snímok, rozpoznanie podvrhu sa vyhodnocuje len na snímkach spredu, spracovanie na serveri sme zrýchlili a opravili sme chybu pri spúšťaní kamery.

Systém má aj obmedzenia. Poloha hlavy sa odhaduje len z piatich bodov, takže je menej presná ako odhad z väčšieho počtu bodov. Proti obídeniu kamery cez virtuálnu kameru chráni iba výzva na pohyb – útok, ktorý by v reálnom čase vytváral pohyby tváre, by vyžadoval ďalšie opatrenia, napríklad overenie zariadenia. Rozpoznávanie podvrhov sme vyhodnotili na staršej databáze s orezanými snímkami a test so živými používateľmi v širšom rozsahu zostáva na doplnenie. Ako rozšírenie sa ponúka použitie modelov, ktoré lepšie fungujú v nových podmienkach [11], odhaľovanie obídenia kamery a ochrana vzorov zrušiteľnými biometrickými vzormi [15].

Zoznam použitej literatúry

[1] EUROPEAN UNION AGENCY FOR CYBERSECURITY (ENISA). *Remote Identity Proofing: Attacks & Countermeasures*. Athens: ENISA, 2022. Dostupné z: `https://www.enisa.europa.eu/publications/remote-identity-proofing-attacks-countermeasures`

[2] WU, Wei, PENG, Hanyang a YU, Shiqi. YuNet: A Tiny Millisecond-level Face Detector. *Machine Intelligence Research*. 2023, roč. 20, č. 5, s. 656–665. DOI: 10.1007/s11633-023-1423-y

[3] DENG, Jiankang, GUO, Jia, YANG, Jing, XUE, Niannan, KOTSIA, Irene a ZAFEIRIOU, Stefanos. ArcFace: Additive Angular Margin Loss for Deep Face Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 2022, roč. 44, č. 10, s. 5962–5979. DOI: 10.1109/TPAMI.2021.3087709

[4] KIM, Minchul, JAIN, Anil K. a LIU, Xiaoming. AdaFace: Quality Adaptive Margin for Face Recognition. In: *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2022, s. 18729–18738. DOI: 10.1109/CVPR52688.2022.01819

[5] ZHONG, Yaoyao, DENG, Weihong, HU, Jiani, ZHAO, Dongyue, LI, Xian a WEN, Dongchao. SFace: Sigmoid-Constrained Hypersphere Loss for Robust Face Recognition. *IEEE Transactions on Image Processing*. 2021, roč. 30, s. 2587–2598. DOI: 10.1109/TIP.2020.3048632

[6] SCHLETT, Torsten, RATHGEB, Christian, HENNIGER, Olaf, GALBALLY, Javier, FIERREZ, Julian a BUSCH, Christoph. Face Image Quality Assessment: A Literature Survey. *ACM Computing Surveys*. 2022, roč. 54, č. 10s, s. 1–49. DOI: 10.1145/3507901

[7] ISO/IEC 29794-5:2025. *Information technology – Biometric sample quality – Part 5: Face image data*. 1. vyd. Ženeva: ISO, 2025. Dostupné z: `https://www.iso.org/standard/81005.html`

[8] HERNANDEZ-ORTEGA, Javier, FIERREZ, Julian, MORALES, Aythami a GALBALLY, Javier. Introduction to Presentation Attack Detection in Face Biometrics and Recent Advances. In: MARCEL, Sébastien, FIERREZ, Julian a EVANS, Nicholas (ed.). *Handbook of Biometric Anti-Spoofing: Presentation Attack Detection and Vulnerability Assessment*. 3. vyd. Singapore: Springer, 2023, s. 203–230. DOI: 10.1007/978-981-19-5288-3_9

[9] YU, Zitong, QIN, Yunxiao, LI, Xiaobai, ZHAO, Chenxu, LEI, Zhen a ZHAO, Guoying. Deep Learning for Face Anti-Spoofing: A Survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 2023, roč. 45, č. 5, s. 5609–5631. DOI: 10.1109/TPAMI.2022.3215850

[10] SUN, Yiyou, LIU, Yaojie, LIU, Xiaoming, LI, Yixuan a CHU, Wen-Sheng. Rethinking Domain Generalization for Face Anti-spoofing: Separability and Alignment. In: *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2023, s. 24563–24574. DOI: 10.1109/CVPR52729.2023.02353

[11] SRIVATSAN, Koushik, NASEER, Muzammal a NANDAKUMAR, Karthik. FLIP: Cross-domain Face Anti-spoofing with Language Guidance. In: *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, 2023, s. 19628–19639. DOI: 10.1109/ICCV51070.2023.01803

[12] WANG, Dong, GUO, Jia, SHAO, Qiqi et al. Wild Face Anti-Spoofing Challenge 2023: Benchmark and Results. In: *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. IEEE, 2023, s. 6380–6391. DOI: 10.1109/CVPRW59228.2023.00679

[13] ISO/IEC 30107-3:2023. *Information technology – Biometric presentation attack detection – Part 3: Testing and reporting*. 2. vyd. Ženeva: ISO, 2023. Dostupné z: `https://www.iso.org/standard/79520.html`

[14] BUSCH, Christoph. Standards for Biometric Presentation Attack Detection. In: MARCEL, Sébastien, FIERREZ, Julian a EVANS, Nicholas (ed.). *Handbook of Biometric Anti-Spoofing: Presentation Attack Detection and Vulnerability Assessment*. 3. vyd. Singapore: Springer, 2023, s. 571–583. DOI: 10.1007/978-981-19-5288-3_21

[15] ABDULLAHI, Sani M., SUN, Shuifa, WANG, Beng, WEI, Ning a WANG, Hongxia. Biometric Template Attacks and Recent Protection Mechanisms: A Survey. *Information Fusion*. 2024, roč. 103, čl. 102144. DOI: 10.1016/j.inffus.2023.102144

[16] EURÓPSKY PARLAMENT A RADA EURÓPSKEJ ÚNIE. Nariadenie (EÚ) 2024/1689 z 13. júna 2024, ktorým sa stanovujú harmonizované pravidlá v oblasti

umelej inteligencie (akt o umelej inteligencii). *Úradný vestník Európskej únie*, L, 2024/1689. Dostupné z: https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[17] OPENCV. *OpenCV Zoo: Models for OpenCV DNN* [softvér]. Dostupné z: https://github.com/opencv/opencv_zoo

[18] MINIVISION AI. *Silent-Face-Anti-Spoofing* [softvér]. 2020. Dostupné z: https://github.com/minivision-ai/Silent-Face-Anti-Spoofing

[19] HUANG, Gary B., RAMESH, Manu, BERG, Tamara a LEARNED-MILLER, Erik. *Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments*. Technical Report 07-49. Amherst: University of Massachusetts, 2007.

[20] ZHANG, Zhiwei, YAN, Junjie, LIU, Sifei, LEI, Zhen, YI, Dong a LI, Stan Z. A Face Antispoofing Database with Diverse Attacks. In: *2012 5th IAPR International Conference on Biometrics (ICB)*. IEEE, 2012, s. 26–31. DOI: 10.1109/ICB.2012.6199754

Dodatok A

Obsah repozitára

Repozitár `https://github.com/opoiasnik/face-auth-antispoofing`:

- `backend/` – serverová časť, testy, vyhodnocovacie skripty,
- `frontend/` – webová aplikácia,
- `docs/` – technická dokumentácia,
- `report/` – zdrojové súbory tejto správy,
- `docker-compose.yml`, `render.yaml` – nasadenie.